



MINISTÉRIO DA EDUCAÇÃO
INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO PARÁ
CAMPUS ANANINDEUA
BACHARELADO EM CIÊNCIA DA COMPUTAÇÃO

RELATÓRIO TÉCNICO-CIENTÍFICO
ASSISTENTE ACADÊMICO IFPA: AGENTE RAG COM RACIOCÍNIO REACT

Componente curricular: Tópicos Avançados em Computação I (Miniprojeto 1)

Discentes: [Nome do Integrante 1 (líder)], [Nome do Integrante 2], [Nome do Integrante 3], [Nome do Integrante 4]

Local e data: Ananindeua – PA, outubro de 2026


1 DETALHAMENTO DA ARQUITETURA DO AGENTE

O assistente combina a Geração Aumentada por Recuperação (RAG), que injeta no contexto do modelo trechos recuperados de uma base externa (LEWIS et al., 2020), com um agente no paradigma ReAct, que intercala raciocínio, ação e observação (YAO et al., 2023). A arquitetura (Figura 1) tem dois fluxos. Na **preparação**, os documentos oficiais (Resolução CONSUP nº 945/2023, PPC e Guia Acadêmico 2025) são lidos pelo `PyPDFLoader`, fatiados, vetorizados com o `text-embedding-3-small` e armazenados no `ChromaDB`. Na **consulta**, a pergunta chega a uma API FastAPI no Railway, passa pela camada de segurança e é entregue ao agente.

Figura 1 – Arquitetura do agente

Arquitetura do Agente RAG — Assistente Acadêmico IFPA

Linha de cima: o caminho de cada pergunta - Linha de baixo: dados, preparação e infraestrutura



Fonte: elaborado pelos autores (2026).

O agente é criado com `create_agent` do LangChain e executado como um grafo LangGraph. O modelo `gpt-4o-mini`, com temperatura zero, realiza o ciclo *Thought* → *Action* → *Observation*: decide se precisa consultar os documentos, chama a ferramenta de busca, lê os trechos e repete até reunir evidência suficiente. A memória de sessão é mantida por um `InMemorySaver`, e um middleware limita o histórico enviado ao modelo a 6 mil tokens.

2 DESENHO DAS TOOLS

As ferramentas foram implementadas como funções Python decoradas com `@tool`. Suas docstrings funcionam como contrato com o modelo: descrevem quando usar a ferramenta, quais argumentos fornecer e como interpretar o retorno (Quadro 1).

Quadro 1 – Ferramentas disponíveis ao agente

Ferramenta	Entrada	Saída e uso
<code>buscar_normas_ifpa</code>	consulta: pergunta reescrita em termos normativos; pensamento: motivo da busca	Até 7 trechos no formato "documento página artigo relevância", ou SEM_EVIDENCIA quando nada é relevante. Uso obrigatório antes de qualquer resposta sobre normas.
<code>listar_documentos_oficiais</code>	Nenhuma	Lista dos documentos indexados, usada quando o usuário pergunta quais fontes o assistente conhece.

Fonte: elaborado pelos autores (2026).

O parâmetro `pensamento` torna o *Thought* explícito e auditável no log, pois modelos com chamada nativa de ferramentas costumam omitir o raciocínio textual. Internamente, a busca é híbrida: a busca vetorial no ChromaDB (4 trechos, distância de cosseno) decide se há evidência, e o índice lexical BM25 (ROBERTSON; ZARAGOZA, 2009), com 3 trechos, complementa com termos exatos, como "abono" ou "trancamento".

3 ESTRATÉGIA DE FATIAMENTO DOS PDFS

O texto é fatiado pelo `RecursiveCharacterTextSplitter` com `chunk_size` de 1200 caracteres (cerca de 300 tokens) e `chunk_overlap` de 200 caracteres (cerca de 17%). Os separadores priorizam a hierarquia das normas — TÍTULO, CAPÍTULO, Seção, Art. e § — antes das quebras genéricas de parágrafo, linha e frase. Quanto ao contexto, a unidade de sentido de uma norma é o artigo com seus parágrafos (em geral de 600 a 1200 caracteres): trechos menores separariam a regra de suas exceções, e maiores misturariam artigos, diluindo o vetor. Quanto ao custo (FinOps), cada busca injeta no máximo cerca de 2.000 tokens, e a indexação completa (~116 mil tokens) custa cerca de US\$ 0,002.

A primeira versão fatiava por página, cortando artigos e levando o agente a atribuir números de artigo errados a parágrafos isolados. Na versão final, o documento é fatiado inteiro, a página de cada trecho é calculada pelo deslocamento no texto e os trechos que começam no meio de um artigo recebem o prefixo "(continuação do Art. N)". O resultado são 480 trechos, dos quais 164 começam exatamente em "Art." e 376 estão rotulados com o artigo a que pertencem.

4 JUSTIFICATIVA DA MITIGAÇÃO DE ALUCINAÇÕES

Modelos de linguagem podem gerar conteúdo fluente, porém sem sustentação nas fontes (JI et al., 2023). Como o roteiro exige que toda resposta sobre normas seja ancorada nos documentos oficiais, a mitigação foi organizada em cinco camadas complementares (Quadro 2).

Quadro 2 – Camadas de mitigação de alucinações

Camada	Mecanismo	Justificativa
Entrada	Limite de 1000 caracteres e detecção de <i>prompt injection</i>	Impede que o usuário altere as regras do agente, sem gerar custo.
Tráfego	Limite de 15 perguntas por minuto por IP	Protege a cota da API contra abuso.
<i>System prompt</i>	Documentos como única fonte, busca e citação obrigatórias, recusa de temas fora do escopo, temperatura zero	Restringe o modelo ao conteúdo recuperado.
Recuperação	Limiar de distância de cosseno (0,75) e retorno SEM_EVIDENCIA	Sem evidência, o agente admite que não encontrou a informação.
Saída	JSON reparado (json-repair) e validado (Pydantic); citações e números de artigo conferidos contra os trechos recuperados	Descarta fontes inventadas e rebaixa a confiança da resposta quando algo não confere.

Fonte: elaborado pelos autores (2026).

Nos testes em produção, o agente citou corretamente o Art. 88 da Resolução nº 945/2023 (frequência mínima de 75%, vedado o abono de faltas), admitiu não encontrar o valor da bolsa de monitoria, ausente da base, e bloqueou a tentativa de *prompt injection* sem custo de API.

REFERÊNCIAS

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO PARÁ. **Guia Acadêmico 2025**. Belém: IFPA, 2025.

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO PARÁ. **Projeto Pedagógico do Curso de Bacharelado em Ciência da Computação**. Ananindeua: IFPA, Campus Ananindeua.

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DO PARÁ. **Resolução CONSUP nº 945/2023**: Regulamento Didático-Pedagógico do Ensino. Belém: IFPA, 2023.

JI, Z. et al. Survey of hallucination in natural language generation. **ACM Computing Surveys**, New York, v. 55, n. 12, p. 1-38, 2023.

LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. **Advances in Neural Information Processing Systems**, [s. l.], v. 33, p. 9459-9474, 2020.

ROBERTSON, S.; ZARAGOZA, H. The probabilistic relevance framework: BM25 and beyond. **Foundations and Trends in Information Retrieval**, Hanover, v. 3, n. 4, p. 333-389, 2009.

YAO, S. et al. ReAct: synergizing reasoning and acting in language models. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS, 11., 2023, Kigali. **Proceedings [...]**. [S. l.]: ICLR, 2023.