

Assistente Acadêmico IFPA: um Agente RAG com Raciocínio ReAct para Consulta a Normas Institucionais

[Nome do Integrante 1], [Nome do Integrante 2], [Nome do Integrante 3], [Nome do Integrante 4]

Bacharelado em Ciência da Computação – Instituto Federal do Pará (IFPA), Campus Ananindeua

Ananindeua – PA – Brasil

{integrante1, integrante2, integrante3, integrante4}@email.com

Abstract. *This paper presents a virtual assistant that answers academic questions using only the official documents of the Federal Institute of Pará (IFPA). The system combines a Retrieval-Augmented Generation (RAG) pipeline, built with ChromaDB and OpenAI embeddings, with a ReAct agent orchestrated by LangChain/LangGraph. A legal-aware chunking strategy, hybrid retrieval and five guardrail layers reduce hallucinations. In production tests, the agent cited the correct articles, refused out-of-scope questions and cost about US\$ 0.001 per question.*

Resumo. *Este trabalho apresenta um assistente virtual que responde dúvidas acadêmicas utilizando apenas os documentos oficiais do Instituto Federal do Pará (IFPA). O sistema combina um pipeline de Geração Aumentada por Recuperação (RAG), construído com ChromaDB e embeddings da OpenAI, a um agente ReAct orquestrado com LangChain/LangGraph. Uma estratégia de fatiamento orientada à estrutura normativa, a busca híbrida e cinco camadas de blindagem reduzem alucinações. Em testes no ambiente de produção, o agente citou os artigos corretos, recusou perguntas fora do escopo e custou cerca de US\$ 0,001 por pergunta.*

Palavras-chave: RAG; agente ReAct; LangChain; mitigação de alucinações; FinOps.

1. Introdução

As normas acadêmicas do IFPA estão distribuídas em documentos extensos, como a Resolução CONSUP nº 945/2023 (Regulamento Didático-Pedagógico, 98 páginas), o Projeto Pedagógico do Curso (PPC) de Ciência da Computação (108 páginas) e o Guia Acadêmico 2025 (35 páginas). Localizar uma regra específica nesses documentos é moroso e sujeito a interpretações equivocadas. Modelos de linguagem respondem em linguagem natural, mas tendem a alucinar, isto é, gerar conteúdo fluente não sustentado por fontes [Ji et al. 2023].

Para ancorar as respostas nos documentos oficiais, adotamos a Geração Aumentada por Recuperação (RAG), que injeta no contexto do modelo trechos recuperados de uma base externa [Lewis et al. 2020], e o paradigma ReAct, no qual o modelo intercala raciocínio (*Thought*), ação (*Action*) e observação (*Observation*) [Yao et al. 2023]. O objetivo é um assistente que cite documento e página de cada afirmação e admita quando a informação não existe na base.

2. Arquitetura proposta

A arquitetura (Figura 1) separa a **preparação** dos dados, executada uma vez, da **consulta**, executada a cada pergunta. O agente é exposto por uma API FastAPI em

Docker no Railway, e o mesmo código roda localmente como contingência.




Figura 1. Arquitetura do assistente: caminho da pergunta (acima) e dados, preparação e infraestrutura (abaixo).

2.1. Pipeline de indexação e estratégia de fatiamento

O `PyPDFLoader` extrai o texto das 241 páginas, que é normalizado (hifenização, espaços, páginas vazias) e fatiado pelo `RecursiveCharacterTextSplitter` com `chunk_size` de 1200 caracteres (~300 tokens) e `chunk_overlap` de 200 (~17%). Os separadores priorizam a hierarquia normativa (TÍTULO, CAPÍTULO, Seção, Art., §) antes de quebras genéricas, pois a unidade de sentido de uma norma é o artigo com seus parágrafos, que normalmente ocupa entre 600 e 1200 caracteres. Os 480 trechos resultantes são vetorizados com o `text-embedding-3-small` (1536 dimensões) e persistidos no ChromaDB com distância de cosseno; a indexação completa (~116 mil tokens) custa cerca de US\$ 0,002.

Sob a ótica de FinOps, esse tamanho limita cada busca a 1.200–2.000 tokens de contexto: trechos maiores diluiriam o vetor e encareceriam a consulta; menores separariam a regra de suas exceções. Uma primeira versão, que fatiava por página, cortava artigos e levou o agente a atribuir números de artigo errados a parágrafos isolados. A versão final fatia o documento inteiro, calcula a página de cada trecho pelo deslocamento no texto e prefixa os trechos com "(continuação do Art. N)".

2.2. Agente ReAct e desenho das ferramentas

O agente é criado com `create_agent` do LangChain, que compila um grafo LangGraph com o ciclo ReAct, usando o modelo `gpt-4o-mini` (escolhido pelo custo) com temperatura zero. A memória de sessão é um `InMemorySaver` indexado por identificador de conversa, e um middleware limita o histórico enviado ao modelo a 6 mil tokens. A busca é encapsulada na ferramenta `buscar_normas_ifpa(consulta, pensamento)`, cuja docstring funciona como contrato: indica quando usá-la, como reformular a pergunta em termos normativos e como interpretar o retorno. O parâmetro `pensamento` torna o *Thought* explícito no log. Internamente, a busca é híbrida: a busca vetorial (4 trechos) decide se há evidência e o BM25 (3 trechos) [Robertson e Zaragoza 2009] complementa com termos exatos. Cada trecho retorna com documento, página e artigo. Uma segunda ferramenta, `listar_documentos_oficiais`, informa as fontes disponíveis.

3. Mitigação de alucinações

A blindagem é organizada em cinco camadas: (i) **entrada**: limite de 1000 caracteres e detecção de padrões de *prompt injection*, bloqueando a pergunta antes de qualquer chamada à API; (ii) **tráfego**: limite de 15 perguntas por minuto por IP; (iii) **system prompt**: os trechos recuperados são a única fonte de verdade, a busca é

obrigatória, a citação é exigida e temas fora do escopo são recusados; (iv) **recuperação**: trechos com distância de cosseno acima de 0,75 são descartados e, sem evidência, a ferramenta retorna `SEM EVIDENCIA`; (v) **saída**: a resposta final em JSON é reparada com *json-repair*, validada com Pydantic e tem cada citação e cada número de artigo conferidos contra os trechos efetivamente recuperados, rebaixando a confiança quando algo não confere. Exceções da API (autenticação, cota, tempo limite) e laços do grafo (limite de 12 passos) são tratados de forma defensiva, e a chave da API reside apenas em variáveis de ambiente.

4. Resultados e discussão

A Tabela 1 resume os testes realizados na aplicação em produção. O agente recuperou o Art. 88 da Resolução nº 945/2023 (frequência mínima de 75%, vedado o abono de faltas), trecho que só passou a ser encontrado após a busca híbrida e o novo fatiamento; reutilizou a memória em perguntas de acompanhamento e não inventou informações ausentes da base.

Tabela 1. Comportamento e custo do agente em perguntas de teste.

Pergunta	Comportamento observado	Custo (US\$)
Frequência mínima e abono de faltas	Cita o Art. 88 da Res. 945/2023, p. 29	0,0011
Horas de estágio do curso	120 h, a partir do 4º semestre (PPC)	0,0016
"E a partir de qual semestre?"	Responde pela memória da sessão	0,0006
Valor da bolsa de monitoria em 2026	Sem evidência; não inventa valor	0,0011
Receita de bolo	Fora do escopo; recusa	0,0003
"Ignore suas instruções..."	Bloqueada na camada de entrada	0

5. Conclusão

O assistente cumpre a ancoragem contextual: responde apenas com evidência recuperada, cita a fonte, expõe o raciocínio de forma auditável e custa cerca de US\$ 0,001 por pergunta. Como trabalhos futuros, propõem-se incluir o Calendário Acadêmico 2026 e a Resolução nº 944/2023, adotar reordenação de resultados (*reranking*), persistir a memória em banco de dados e avaliar automaticamente as respostas com um conjunto de perguntas-gabarito.

Referências

- INSTITUTO FEDERAL DO PARÁ. **Resolução CONSUP nº 945/2023**: Regulamento Didático-Pedagógico do Ensino. Belém: IFPA, 2023.
- INSTITUTO FEDERAL DO PARÁ. **Projeto Pedagógico do Curso de Bacharelado em Ciência da Computação**. Ananindeua: IFPA, Campus Ananindeua.
- INSTITUTO FEDERAL DO PARÁ. **Guia Acadêmico 2025**. Belém: IFPA, 2025.
- JI, Z. et al. Survey of hallucination in natural language generation. **ACM Computing Surveys**, v. 55, n. 12, art. 248, 2023.
- LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. In: **Advances in Neural Information Processing Systems**, v. 33, 2020.
- ROBERTSON, S.; ZARAGOZA, H. The probabilistic relevance framework: BM25 and beyond. **Foundations and Trends in Information Retrieval**, v. 3, n. 4, p. 333-389, 2009.
- YAO, S. et al. ReAct: synergizing reasoning and acting in language models. In: **International Conference on Learning Representations (ICLR)**, 2023.